

# Siatki hiperparametrów modeli

## 1 Logistic Regression

### RandomizedSearch

Parametr	Zakres / Rozkład
<code>solver</code>	<code>{lbfgs}</code>
<code>penalty</code>	<code>{l2}</code>
<code>C</code>	<code>loguniform(1e-3, 1e3)</code>
<code>max_iter</code>	<code>randint(1000, 4000)</code>
<code>solver</code>	<code>{saga}</code>
<code>penalty</code>	<code>{l1, l2, elasticnet}</code>
<code>l1_ratio</code>	<code>uniform(0.05, 0.9)</code>
<code>C</code>	<code>loguniform(1e-3, 1e3)</code>
<code>max_iter</code>	<code>randint(1000, 4000)</code>

Tabela 1: Przestrzenie hiperparametrów Logistic Regression — RandomizedSearch.

### BayesSearch

Pod-przestrzeń (liczba prób)	Definicja
<code>lbfgs + l2 (25)</code>	<code>solver = Categorical([lbfgs])</code> <code>penalty = Categorical([l2])</code> <code>C = Real(1e-3, 1e3, prior='log-uniform')</code> <code>max_iter = Integer(1000, 4000)</code>
<code>saga + {l1,l2} (25)</code>	<code>solver = Categorical([saga])</code> <code>penalty = Categorical([l1, l2])</code> <code>C = Real(1e-3, 1e3, prior='log-uniform')</code> <code>max_iter = Integer(1000, 4000)</code>
<code>saga + elasticnet (25)</code>	<code>solver = Categorical([saga])</code> <code>penalty = Categorical([elasticnet])</code> <code>l1_ratio = Real(0.05, 0.9)</code> <code>C = Real(1e-3, 1e3, prior='log-uniform')</code> <code>max_iter = Integer(1000, 4000)</code>

Tabela 2: Przestrzenie hiperparametrów Logistic Regression — BayesSearch.

**Uzasadnienie:** Parametr `C` odpowiada za siłę regularyzacji (niższe wartości  $\Rightarrow$  silniejsza regularyzacja). Solver `saga` umożliwia wykorzystanie rzadkiej regularizacji L1 oraz ElasticNet.

Przedziały iteracji zapewniają wystarczającą liczbę kroków optymalizacji nawet przy danych trudnych do konwergencji.

## 2 Random Forest

### RandomizedSearch

Parametr	Zakres / Rozkład
<code>n_estimators</code>	<code>randint(10, 200)</code>
<code>max_depth</code>	<code>randint(2, 20)</code>
<code>min_samples_split</code>	<code>randint(2, 8)</code>
<code>min_samples_leaf</code>	<code>randint(1, 5)</code>
<code>max_features</code>	<code>{sqrt, log2, None}</code>
<code>bootstrap</code>	<code>{True, False}</code>
<code>criterion</code>	<code>{gini, entropy, log_loss}</code>
<code>class_weight</code>	<code>{None, balanced}</code>

Tabela 3: Przestrzenie hiperparametrów Random Forest — RandomizedSearch.

### BayesSearch

Parametr	Przestrzeń
<code>n_estimators</code>	<code>Integer(10, 200)</code>
<code>max_depth</code>	<code>Integer(2, 20)</code>
<code>min_samples_split</code>	<code>Integer(2, 8)</code>
<code>min_samples_leaf</code>	<code>Integer(1, 5)</code>
<code>max_features</code>	<code>Categorical([sqrt, log2, None])</code>
<code>bootstrap</code>	<code>Categorical([True, False])</code>
<code>criterion</code>	<code>Categorical([gini, entropy, log_loss])</code>
<code>class_weight</code>	<code>Categorical([None, balanced])</code>

Tabela 4: Przestrzenie hiperparametrów Random Forest — BayesSearch.

**Uzasadnienie:** Zakres liczby drzew (10–200) zapewnia kompromis między dokładnością a czasem treningu. Zmienność głębokości i liczby próbek na liść pozwala regulować poziom przeuczenia. Użycie różnych kryteriów i wag klas umożliwia dopasowanie modelu do danych niezerównoważonych.

### 3 XGBoost

#### RandomizedSearch

Parametr	Zakres / Rozkład
n_estimators	randint(300, 1200)
max_depth	randint(3, 8)
learning_rate	loguniform(0.01, 0.1)
subsample	uniform(0.6, 0.4)
colsample_bytree	uniform(0.6, 0.4)
min_child_weight	randint(1, 8)
gamma	uniform(0.0, 3.0)
reg_lambda	uniform(0.0, 10.0)
reg_alpha	uniform(0.0, 5.0)
scale_pos_weight	uniform(1.0, 5.0)

Tabela 5: Przestrzenie hiperparametrów XGBoost — RandomizedSearch.

#### BayesSearch

Parametr	Przestrzeń
n_estimators	Integer(300, 1200)
max_depth	Integer(3, 8)
learning_rate	Real(0.01, 0.1, prior='log-uniform')
subsample	Real(0.6, 1.0)
colsample_bytree	Real(0.6, 1.0)
min_child_weight	Integer(1, 8)
gamma	Real(0.0, 3.0)
reg_lambda	Real(0.0, 10.0)
reg_alpha	Real(0.0, 5.0)
scale_pos_weight	Real(1.0, 5.0)

Tabela 6: Przestrzenie hiperparametrów XGBoost — BayesSearch.

**Uzasadnienie:** Zakresy odzwierciedlają standardowe praktyki dla XGBoost: `learning_rate` od 0.01 do 0.1 zapewnia kompromis między szybkością nauki a stabilnością. Parametry regularizacji (`reg_alpha`, `reg_lambda`) ograniczają przeuczenie, a `scale_pos_weight` kompensuje nie zrównoważone klasy.